

Machine Learning

Machine Learning

Una introducción práctica (basada en IBM Think):
<https://www.ibm.com/think/topics/machine-learning>

De datos → modelo → decisions...

D. Sierra Porta (Feb 2026)

Machine learning is a field of

1. Arthur Samuel (atribuida a 1959)

“Machine Learning is the field of study that gives computers the ability to learn without being explicitly programmed.”

Idea clave: aprendizaje como *capacidad de mejorar* sin programar reglas explícitas.

Nota de rigor: esta frase es famosísima, pero varias fuentes señalan que **no es fácil verificarla literalmente dentro del paper de 1959**; por eso conviene citarla como “atribuida a”.

Machine learning is a field which

2. Tom M. Mitchell (1997, definición formal T–P–E)

“A computer program is said to learn from experience E ... if its performance ... improves with experience”

Idea clave: ML = *mejorar desempeño (P) en una tarea (T) gracias a experiencia (E)*. (La cita completa introduce explícitamente T y P).

Machine learning is a field which

3. Peter Flach (2012)

“Machine learning is the systematic study of algorithms and systems that improve their knowledge or performance with experience.”














Idea clave: enfatiza ML como **estudio sistemático** (no solo “trucos”), y como mejora por experiencia.

Machine learning is a field which



4. An Introduction to Statistical Learning (conexión ML ↔ estadística)

“Statistical learning refers to a vast set of tools for understanding data.”

Idea clave: en la tradición estadística, ML/SL se presenta como **herramientas para entender y predecir** a partir de datos (supervisado y no supervisado).



Mis recomendaciones....



¿Qué es Machine Learning?

En machine learning, el objetivo es **ajustar los parámetros** de una función/modelo para que sus salidas sean cada vez más precisas usando datos.

- Aprende patrones y relaciones a partir de ejemplos (datos).
- Busca **generalizar**: funcionar bien en datos nuevos, no solo en los de entrenamiento.
- Se entrena minimizando una **función de pérdida** que mide el error frente a una referencia (ground truth) cuando existe.

¿Cómo aprende un modelo?

Ejemplo de función con parámetros

$$\text{Precio} = (A \cdot m^2) + (B \cdot \#\text{habitaciones}) \\ - (C \cdot \text{edad}) + \text{base}$$

A, B y C son **parámetros**: el entrenamiento busca sus valores óptimos.

La idea central: ajustar parámetros para reducir pérdida y mejorar precisión.

Ciclo de aprendizaje (alto nivel)

Datos (features)

Modelo

Pérdida (error)

Optimización

Predicción

Tipos de Machine Learning

IBM agrupa los métodos en tres paradigmas principales según su objetivo de entrenamiento:

Supervisado

- Tiene referencia (ground truth).
- Optimiza para predecir “lo correcto”.

Ejemplos:

- Regresión (valor continuo)
- Clasificación (clase/categoría)

No supervisado

- No hay etiquetas.
- Busca patrones internos: similitud, dependencias, agrupaciones.

Ejemplos:

- Clustering
- Asociación
- Reducción de dimensionalidad

Reforzamiento (RL)

- Un agente actúa en un entorno.
- Aprende por prueba y error.
- Objetivo: maximizar recompensa.

Ejemplos:

- Robótica
- Videojuegos
- Control y planificación


Supervised learning (aprendizaje supervisado)

Idea clave


Se entrena comparando la salida del modelo contra un **ground truth** y ajustando parámetros para minimizar la pérdida.

Dos familias de tareas

- **Regresión:** predice valores continuos (precio, duración, temperatura).
- **Clasificación:** predice clases/decisiones discretas (spam/no spam, fraude/no fraude).
- **Métrica + validación:** evaluar generalización antes de “confiar” en el modelo.



Unsupervised learning (aprendizaje no supervisado)



¿Qué hace?

Busca **patrones internos** en datos sin etiquetas: similitudes, correlaciones o agrupaciones.

Funciones típicas

Suele usarse para explorar, resumir o preparar datos para modelos supervisados.

- **Clustering:** segmentación de clientes, detección de patrones de fraude.
- **Asociación:** reglas/correlaciones (p. ej., recomendación).
- **Reducción de dimensionalidad:** compresión, visualización, preprocesamiento.


Reinforcement learning (aprendizaje por refuerzo)

Idea clave

Un **agente** interactúa con un **entorno** y aprende una estrategia (política) mediante prueba y error para **maximizar recompensa**.

Componentes (lenguaje estándar RL)


- **Estado:** información disponible para decidir.
- **Acciones:** decisiones permitidas.
- **Señal de recompensa:** feedback tras cada acción.
- **Política:** regla/función que mapea estados a acciones.




Deep learning (dentro de ML) y próximos pasos

Deep learning en 30 segundos

- Usa redes neuronales con muchas capas (modelos “profundos”).
- Funciones de activación no lineales permiten capturar patrones complejos.
- Backprop + descenso por gradiente optimizan millones de parámetros.
- Suele requerir más datos y cómputo que ML “tradicional”.



Steps in ML



Data



Model

A model is the relationship between features and the label.

An ML model is a mathematical model that generates predictions by finding patterns in your data.

ML models generate predictions using the patterns extracted from the input data.

A model represents what was learned by a machine learning algorithm.

The model is the “thing” saved after training; it contains the rules, numbers, and algorithm-specific structures needed to make predictions.

Tabular data to predict whether a car is stolen or not

Features

Example No.	Color	Type	Origin	S stolen?
1	Red	Sports	Domestic	Yes
2	Red	Sports	Domestic	No
3	Red	Sports	Domestic	Yes
4	Yellow	Sports	Domestic	No
5	Yellow	Sports	Imported	Yes
6	Yellow	SUV	Imported	No
7	Yellow	SUV	Imported	Yes
8	Yellow	SUV	Domestic	No
9	Red	SUV	Imported	No
10	Red	Sports	Imported	Yes

Label

Label

The output you get from your model after training is called a label.

A label is the thing we're predicting.

For example, the value of the y variable in a simple linear regression model is the label.

Suppose you give your model data like a person's age, height, and hair length, and then the model predicts whether the person is male or female. Then "male" or "female" is the label.

Features

Features are the fields used as input.

A feature is one column of the data in your input set.

For instance, if you're trying to predict the type of pet someone will choose, your input features might include age, home region, family income, etc.

Feature means a property of your training data.

A feature is the input you have fed to the model or system.

In simple linear regression, the values of x are the features.

The goal of machine learning is to

The goal of machine learning is to develop methods that can automatically detect patterns in data, and then to use the uncovered patterns to predict future data or other outcomes of interest.

— Kevin P. Murphy

Machine Learning

Based On	Supervised machine learning	Unsupervised machine learning
Input Data	Algorithms are trained using labeled data.	Algorithms are used against data which is not labelled
Computational Complexity	Supervised learning is a simpler method.	Unsupervised learning is computationally complex
Accuracy	Highly accurate and trustworthy method.	Less accurate and trustworthy method.